

多变量解析とは何か

单变量解析

- 平均

1,2,3,4,5の平均値は、 $(1+2+3+4+5)/5=3$

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

- 分散

1,2,3,4,5の(不偏)分散は2.5

(不偏)分散 $\sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$

- 標準偏差


1,2,3,4,5の標準偏差は1.58

(不偏)標準偏差 $\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2}$

单变量解析と多变量解析の違い


- 单变量解析

- 1つの变数、または变数が複数ある場合でも、それぞれの变数の平均、分散などを考える




- 多变量解析

- 多变量解析は、複数の变数をまとめた1つの变数である合成变数の统计(平均や分散など)を考える
- 主成分分析は、複数の变数をまとめた1つの变数である主成分スコアの分散を考える




合成変数とは？ 身長と体重から新たな変数を作る




身長と体重の2つの変数から、新しい変数を作るとすれば、
どのようなものが考えられるでしょうか？


元の変数(身長、体重)から新たな変数(体の大きさ)を作る




元の変数(身長、体重)から新たな変数(スタイル)を作る



主成分分析との関係




身長・体重と実際のデータとの違い



実際のデータでは変数の組み合わせが多く、身長と体重を
体の大きさで代表するというように、直感的に考えることは難しい

多変量解析を用いたデータの可視化



データを可視化し、群や時系列の情報など
表現型を表す(主)成分を見つける

主成分係数を用いた重要な変数の選び方

身長と体重の例で言えば、

$$\begin{matrix} \text{体の大きさ} \\ (\text{合成変数}) \end{matrix} = \begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{bmatrix} = \begin{bmatrix} x_{11} \\ x_{21} \\ \vdots \\ x_{n1} \end{bmatrix} w_1 + \begin{bmatrix} x_{12} \\ x_{22} \\ \vdots \\ x_{n2} \end{bmatrix} w_2$$

身長
体重

実際のデータでは、

$$\begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{bmatrix} = \begin{bmatrix} x_{11} \\ x_{21} \\ \vdots \\ x_{n1} \end{bmatrix} w_1 + \begin{bmatrix} x_{12} \\ x_{22} \\ \vdots \\ x_{n2} \end{bmatrix} w_2 + \cdots + \begin{bmatrix} x_{1p} \\ x_{2p} \\ \vdots \\ x_{np} \end{bmatrix} w_p$$

w : 重み・主成分係数・固有ベクトル

例えば係数 w_2 の値が大きければ、

第1(主)成分と元のデータの2番目の変数との関連が高い

データを可視化し、着目した(主)成分と関連の高い変数を選ぶ

多变量解析

・多变量解析とは

- 統計学において、複数の独立変数(説明変数)からなる多变量データを統計的に扱う手法。主成分分析、因子分析、クラスター分析などがある。

“<https://ja.wikipedia.org/wiki/多变量解析>” より一部改変



変数

$$\begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} & \cdots & x_{1p} \\ x_{21} & x_{22} & x_{23} & x_{24} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & x_{n3} & x_{n4} & \cdots & x_{np} \end{bmatrix}$$

観測された変数の数が1つではなく複数ある
(測定項目、検査項目など)

主成分分析


・ 主成分分析とは

- ・ 主成分分析は1901年にカール・ピアソンによって導入された。ピアソンとは独立に1930年代にハロルド・ホテリングによっても導入され、**主成分分析 (principal component analysis、PCA)** と呼ばれるようになった。

“<https://ja.wikipedia.org/wiki/主成分分析>” より一部改変



1890年の米国国勢調査の
データ処理で初めて使用された
タビュレーティングマシン



1937年から1942年に
かけて開発され、世界最初の
コンピューターとも言われる
ABCマシン(の復元)



1957年にNASAで使用される
IBM704(大型コンピュータ)
1968年に統計ソフトウェアの
SPSS 1がリリース

データの集計 → 連立方程式の計算 → 多変量解析

Wikipediaより一部改変

多変量解析といつても色々な方法がある どの方法を用いるべきか？

- 分野によって、主に用いられる統計解析手法は異なる
 - 歴史的な背景で決まっていることが多い
 - その分野の論文を見ると、概ね決まって同じ解析手法が用いられている
 - その分野で最も良く用いられている方法を学ぶのが効率的
- 本セミナーでは**主成分分析**と**PLS**を中心に説明
 - 化学・生物(ケモメトリックス)分野での多変量解析としては、**主成分分析**と**Partial Least Squares(PLS)**が最も良く用いられている
- その他の手法
 - 心理学におけるパーソナリティの特性論的研究など、心理尺度の研究手法としては**因子分析**が主に用いられている

“<https://ja.wikipedia.org/wiki/因子分析>” を一部改変

ケモメトリックス(計量化学)は、 化学・生物分野での多変量解析

・ケモメトリックス、計量化学とは

- ・ 数理科学、統計学、機械学習、パターン認識、データマイニングなどの手法により、(広義の) 化学分野における諸問題を解決しようとする分野である
- ・ 計量化学では実験で得られた(多くの場合)大量のデータに対し、次元の圧縮・視覚化・回帰・判別・分類などを行うことによって、実験結果の解釈に重要な情報を提供することを目的とする
- ・ 1960年代後半から1970年代前半にかけて、コワルスキ、ウォルドらの活躍によってであり、ケモメトリックスという用語は、ウォルドによって初めて用いられた
 - ・ SPSS 1がリリースされたのと同時期であることから、この時代から実際のデータの解析として、多変量解析が一般に広く使われるようになったのでは?


“<https://ja.wikipedia.org/wiki/計量化学>”より一部改変

メタボロミクス

- メタボロミクス、メタボローム解析とは
 - メタボロミクスとは、アミノ酸、有機酸、脂肪酸、糖など、分子量が約1000以下の低分子の代謝物(メタボライト)を網羅的に解析すること
- サンプル
 - 動物の臓器、微生物の培養サンプル、人の血液、尿など様々な種類のサンプルを、質量分析装置で測定を行い、メタボロームデータを取得する
- 応用範囲
 - 薬剤の作用機序の解明や、疾患バイオマーカーの探索、食品の機能性研究など様々な研究に利用されている
- 多変量解析の利用
 - 主成分分析やPLSを用いたデータの可視化とローディングを用いて重要な代謝物を選ぶ


メタボロミクスの研究例

絶食マウス肝臓のメタボロームデータ



Yamamoto et al., "Statistical hypothesis testing of factor loading in principal component analysis and its application to metabolite set enrichment analysis" BMC Bioinformatics, (2014) 15(1):51.

主成分分析を用いたデータの可視化の例




身長・体重での合成変数「体の大きさ」と同様に**合成変数を計算**

↓ 実際のデータでは変数の組み合わせが多く、身長と体重を体の大きさで代表するというように、直感的に考えることは難しい


データを可視化した後に**着目する主成分スコア(合成変数)**を決める

絶食マウスでの主成分分析の解析例

データの可視化



重み(主成分)係数を用いて
変数を選ぶ (+)



合成変数に対する主成分係数 w から変数を選ぶ

⇒ 実際は、主成分負荷量を用いて重要な変数を選ぶ